FUNDAMENTOS DE BASES DE DATOS

Capítulo 4

NORMALIZACIÓN

INTRODUCCIÓN

 Hemos agrupado atributos en relaciones de acuerdo a nuestro sentido común, ayudados con el mapeo del Modelo ER al Modelo Relacional. Cuál agrupamiento es el mejor?

- Una GUIA de chequeo informal de calidad de diseño es de la base de datos es la siguiente:
- (tomado del Material de apoyo. Dra. Elzbieta Malinowski Gajda)

- 1. Semántica de los atributos de la relación
 - La semántica indica cómo se interpretan los atributos guardados en la tupla, en otras palabras, cómo los valores en la tupla relacionan entre sí.
 - □Cada vez que agrupamos los atributos tenemos que revisar que tengan algún sentido común o relación entre sí.

 GUIA #1: Diseñe un esquema relacional que no combine atributos de diferentes entidades o de diferentes relaciones.

- Ejemplo de diseños pobres:
- *EMP_DPTO (NombreE, NSS, FechaN, Direccion, NumeroD, NombreD, NSSGte)

*EMP_PRY (NSS, NumeroP, Horas, NombreE, NombreP, LugarP)

- 2. Información redundante en las tuplas y anomalía en las actualizaciones
 - Una meta del diseño es minimizar el espacio para guardar las relaciones.
 - ☐ Agrupando atributos disminuye la cantidad de espacio, ver ejemplo anterior.

EJEMPLO

C	édı	ula	Nombre paciente	Dirección	Númer o Médico	Nombre Médico	Especialidad Médico	Ubicación médico
2	30	3776	Carlos	Alajuela	125	Mario	Neurología	H. México
3	21	4568	María	Heredia	125	Mario	Neurología	H. México
4	35	9087	Pedro	Alajuela	130	Carmen	Cardiología	San Rafael
1	76	2344	Adrián	San José	135	Isabel	Hematologí a	Max Peralta
2	76	4352	Juanita	San José	135	Isabel	Hematologí a	Max Peralta
6	78	9114	Cecilia	Limón	135	Isabel	Hematologí a	Max Peralta

EJEMPLO

¿ Qué ocurre si se borra la tupla donde se encuentra el paciente Pedro?

¿Qué sucede si Erika reemplaza a Isabel?

Hay que utilizar el proceso de normalización, que consiste en obtener una serie de relaciones, a partir de la original sin perder el contenido inicial.

- La repetición de información origina las siguientes anomalías:
- a) Anomalía al insertar:

Insertando un empleado en la relación EMP_DEPT tenemos que insertar la información de departamento, aunque el empleado no haya sido asignado a ningún departamento. Y la información del departamento debe ser correcta para asegurar consistencia de datos.

a) Anomalía al insertar: (continuación)

Además, para insertar un nuevo departamento se necesita asignarle por lo menos un empleado, porque NSS (que es llave) no puede tener un valor nulo.

GUIAS DE CHEQUEO(Anomalías)

b) Anomalía al borrar:

Si necesitamos borrar el último empleado de un departamento, necesitamos borrar ese departamento porque no podemos mantener la información sin el valor en la llave primaria(NSS).

GUIAS DE CHEQUEO(Anomalías)

c) Anomalía al modificar:

Si cambiamos el valor de algunos de los atributos referentes a un departamento, tenemos que cambiarlo en todas las tuplas que representan los empleados de este departamento para asegurarnos de la consistencia de la base de datos.

• GUIA #2:

Diseñe la base de datos de forma que no ocurran las anomalías de actualizaciones (insertar, borrar y modificar).

EJEMPLO

Paciente

Cédula	Nombre paciente	Dirección	Número Médico
2303776	Carlos	Alajuela	125
3214568	María	Heredia	125
4359087	Pedro	Alajuela	130
1762344	Adrián	San José	135
2764352	Juanita	San José	135
6789114	6789114 Cecilia		135



Número Médico	Nombre Médico	Especialidad Médico	Ubicación médico
125	Mario	Neurología	H. México
125	Mario	Neurología	H. México
130	Carmen	Cardiología	San Rafael
135	Isabel	Hematología	Max Peralta
135	Isabel	Hematología	Max Peralta
135	Isabel	Hematología	Max Peralta

- 3. Valores nulos en las tuplas
- Si en algún diseño agrupamos muchos atributos que no tienen una relación clara entre ellos, podemos tener un sistema con muchos valores nulos, lo cual malgasta espacio y dificulta el entendimiento de los atributos.
- Ejm. Solo el 10% de los empleados tienen oficinas individual.

- 3. Valores nulos en las tuplas (continuación)
- Los valores nulos se pueden interpretar como:
 - El atributo no se aplica a la relación
 - El valor del atributo para esa tupla es desconocido
 - El valor del atributo es conocido pero todavía no se ha recopilado.

GUIA #3:

Hasta donde sea posible evite poner atributos cuyos valores puedan ser nulos. Si los valores nulos son inevitables, asegúrese de que sean usados sólo en casos excepcionales y no sean aplicados a la mayoría de las tuplas de la relación.

4. Spurious tuplas (descomposición con pérdida de información)

Tuplas incorrectas al realizar un join incorrecto o se pierde información.

□El problema consiste en que el atributo común en las dos tablas del join no es llave primaria ni llave externa para ninguna de las dos relaciones.

- Spurious tuplas (continuación)
- EMP_PLOC (Nombre, LugarP)
- EMP_PROJI (NSS, NumeroP, Horas, NombreP, LugarP)
- Si se hace un join por el campo común LugarP:

• GUIA #4:

Diseñe los esquemas de las relaciones de forma que la operación "join" entre las tuplas se efectúe usando las llaves primarias o llaves externas de las relaciones, así se garantiza que no se produzcan nuevas tuplas incorrectas o se pierdan algunas.

 Existen otras guías más formales para el diseño de la base de datos relacional, denominadas PROCESO DE NORMALIZACIÓN, para la cual se usan como base las DEPENDENCIAS FUNCIONALES.

PROCESO DE NORMALIZACIÓN

• PASOS:

- Cálculo de las dependencias funcionales, multivaluadas, y jerárquicas que existen entre los atributos de la relación.
- Cálculo del recubrimiento minimal
- Aplicación de las formas normales.

a) DEPENDENCIAS FUNCIONALES

Sea R un esquema de relación y sean X, Y subconjuntos de atributos de R. Se dice que X depende funcionalmente de Y si para cada valor de X solamente existe un valor posible para Y

$$X \rightarrow Y$$

Si para cualesquiera tuplas t1 y t2 de una relación R de este esquema tal que

$$t_1[X] = t_2[X]$$
 entonces $t_1[Y] = t_2[Y]$

X se conoce como determinante

Y se conoce como dependiente o implicado

EJEMPLO: CHOFER

Cédula	Nombre	Dirección	F_ingreso	#_Placa
2303776	Juan Mora	Alajuela	12/06/91	123456
1486756	Juan Mora	Heredia	10/12/87	103626
5456789	María Salas	Alajuela	10/12/87	123456
4567890	Carlos Mata	San José	12/11/86	67896

Cédula → Nombre

- DF Trivial si Y es un subconjunto de X
 - Nombre_Prof → Nombre_Prof
- DF Elemental si Y es el único atributo, se trata de una dependencia plena (no parcial) y no trivial
 - Nombre_Prof → DNI_Prof

DF Transitiva si en el esquema R({X,Y,Z})
 existen las dependencias X → Y; X → Z;
 Y -/ → X

- Nombre_Prof -> Código_Postal;
- Código Postal → Ciudad;
- Código_Postal –/ → Nombre_Prof;
- Nombre_Prof → Ciudad

 DF total: es la dependencia X → Y en la cual la eliminación de cualquier atributo de X invalida la dependencia.

Sean X,Y, Z subconjuntos de atributos de una relación R, en donde se verifican las dependencias funcionales $X \rightarrow Y$ $y Y \rightarrow Z$ entonces las siguientes reglas se cumplen:

Regla de la Reflexividad

Si X es un conjunto de atributos y Y \subseteq X, entonces se cumple X \rightarrow Y.

Cédula > Cédula

Regla de Amplificación

Si $X \rightarrow Y$ y Z es un conjunto de atributos, entonces se cumple $XZ \rightarrow YZ$

Cédula > nombre

 \Rightarrow Cédula \cup #placa \rightarrow nombre \cup #placa

Regla de Transitividad

Si se cumplen ($X \rightarrow Y y Y \rightarrow Z$) $\Rightarrow X \rightarrow Z$

Cédula → nombre_empleado, nombre_empleado → dpto

⇒ Cédula → dpto

 Usando estos tres axiomas de Armstrong repetidamente se genera el conjunto completo de todas la DFs posibles que pueden inferirse del conjunto de las Dependencias Funcionales especificadas en un esquema relacional R.

Estas reglas son válidas porque no generan dependencias funcionales incorrectas. Y además su aplicación repetitiva genera la totalidad de relaciones válidas.

Algunas <u>reglas adicionales</u> para complementar y simplificar el cálculo iniciado con los axiomas de Armstrong:

OTRAS REGLAS DE INFERENCIA

Regla de UNION:

Si se cumplen $X \rightarrow Y$ y $X \rightarrow Z$, entonces se cumple $X \rightarrow YZ$

Cédula -> nombre_empleado

Cédula -> dpto

⇒ Cédula → nombre_empleado, dpto

OTRAS REGLAS DE INFERENCIA

Regla de DESCOMPOSICIÓN

Si se cumple $X \rightarrow YZ$ entonces se cumple que $X \rightarrow Y$ y $X \rightarrow Z$

Cédula \rightarrow nombre_empleado, dpto \Rightarrow

Cédula -> nombre_empleado

Cédula → dpto

OTRAS REGLAS DE INFERENCIA

Regla de Pseudotransitividad:

Si se cumplen $X \rightarrow Y$ y $YZ \rightarrow W$) entonces se cumple $XZ \rightarrow W$

Cédula → nombre_empleado
 Nombre_empleado, horario → dpto
 ⇒ Cédula, horario → dpto

$$R = (A.B.C.G.H.I)$$

- A → H puesto que se cumplen A → B y B → H (xtransitividad)
- CG → HI puesto que
 CG → H y CG → I
 (xunion)

$$\{A \rightarrow B, A \rightarrow C, CG \rightarrow H, CG \rightarrow I, B \rightarrow H\}$$

 AG → I primero, ya que A → C por amplificación se observa que AG → CG.

Segundo, como CG \rightarrow I por transitividad entonces AG \rightarrow I.

EJEMPLO

b) DEPENDENCIAS MULTIVALUADAS

 Sean X y Y dos descriptores, X multidetermina a Y si para cada valor de X existe un conjunto bien definido de valores posibles en Y, con independencia del resto de atributos de la relación.

 $\bullet X \rightarrow \rightarrow Y$

b) DEPENDENCIAS MULTIVALUADAS

Nombre multidetermina Titulación

Nombre	Titulación
Felipe	Magister en Música
Felipe	Ingeniero Eléctrico
Antonio	Ingeniero Civil

Nombre → → Titulación

b) DEPENDENCIAS MULTIVALUADAS

- Jerárquicas $X \rightarrow Y|Z$
- Nombre multidetermina Titulación y Proyecto

Nombre	Titulación	Proyecto
Felipe	Magister en Música	Α
Felipe	Ingeniero Eléctrico	В
Antonio	Ingeniero Civil	Α

CALCULO RECUBRIMIENTO MINIMAL

- Terminé de descubrir dependencias funcionales?
- Un conjunto de dependencias es mínimo, cuando se cumplen las siguientes condiciones:
- a) Todas sus dependencias son elementales, es decir, que todas sus dependencias son no triviales y tengan un único atributo implicado.

CALCULO RECUBRIMIENTO MINIMAL

- b) No existe en ninguna de las dependencias atributos extraños.
- Un atributo A perteneciente a X <u>es extraño</u> en la dependencia X → Y si la dependencia (X-A) → Y se deduce del resto de las dependencias de la relación mediante los axiomas de Armstrong.
- Ejm: R(ABC) {A → C, AB → C} Como el atributo A implica funcionalmente a C, el atributo B es redundante en la segunda dependencia.

CALCULO RECUBRIMIENTO MINIMAL

c) No existe en la relacion ninguna dependencia redundante. Una dependencia es redundante si sus implicados se deducen a partir del resto de las dependencias de la relacion.

Ejm: R(ABC) $\{A \rightarrow B, B \rightarrow C, A \rightarrow C\}$ Como el atributo A determina transitivamente a C, la ultima dependencia $A \rightarrow C$ es redundante.

EL PROCESO DE NORMALIZACIÓN

- El proceso de normalización es un método propio del modelo relacional.
- Consiste en descomponer las relaciones originales en otras más pequeñas con el fin de:
 - Eliminar anomalías de actualizaciones
 - Eliminar duplicados innecesarios de los datos

EL PROCESO DE NORMALIZACIÓN

El proceso de normalización se compone de una serie de seis etapas llamadas formas normales.

- I FN
- 2 FN
- 3 FN
- 3 FNBC (BOYCE-CODD)
- 4FN
- 5FN

PRIMERA FORMA NORMAL IFN

Se dice que una relación esta en IFN si cada uno de sus atributos tiene valores del dominio y los valores de cada uno de esos atributos son componentes atómicos.

PRIMERA FORMA NORMAL

Solución:

Cuando los atributos de las relaciones contienen valores no atómicos (por ejemplo conjunto de valores), para obtener la IFN se necesita aplanar los archivos.

- No estar en IFN provoca:
 - Redundancia de datos
 - Anomalías en insertar, borrar y modificar

Empleado

Cédula	Fecha pago 1	Monto 1	Fecha pago 2	Mont o 2	Fecha pago 3	Monto 3
123	01/05/96	50000	01/06/96	55000	01/07/96	55000
134	01/05/96	70000			01/07/96	70000
245	01/01/96	60000	01/06/96	60000	01/07/96	60000

Empleado

Cédula	Fecha_pago	Monto
123	01/05/96	50000
134	01/05/96	70000
245	01/05/96	60000
123	01/06/96	55000
245	01/06/96	60000
123	01/07/96	55000
134	01/07/96	70000
245	01/07/96	60000



Número_viaje	Sitio
100	Irazú, Volcán
125	Sámara, Playa
150	Pacuare, Río

Tour

Número_Viaje	Nombre_sitio	Tipo_sitio
100	Irazú	Volcán
125	Sámara	Playa
150	Pacuare	Río

Titulaciones

Nombre	Titulaciones
Felipe	Informático
	Eléctrico
Antonia	Música

Titulaciones

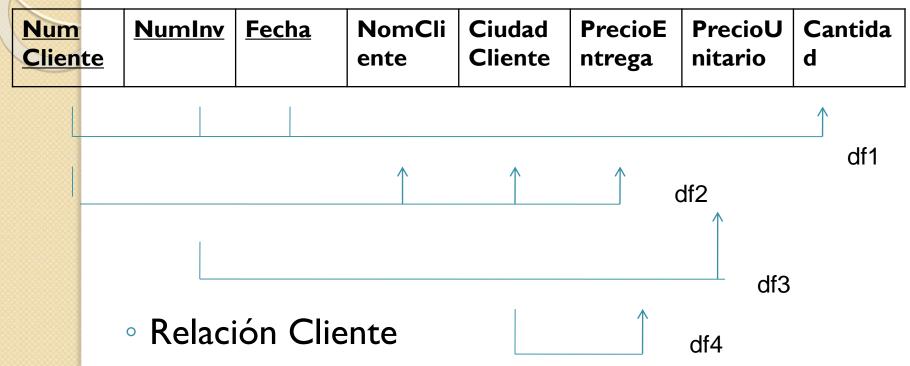
Nombre	Titulaciones
Felipe	Informático
Felipe	Eléctrico
Antonia	Música

SEGUNDA FORMA NORMAL 2FN

Una relación se encuentra en 2FN si se encuentra en 1FN y si ningún atributo no llave de la relación depende parcialmente de la llave primaria.

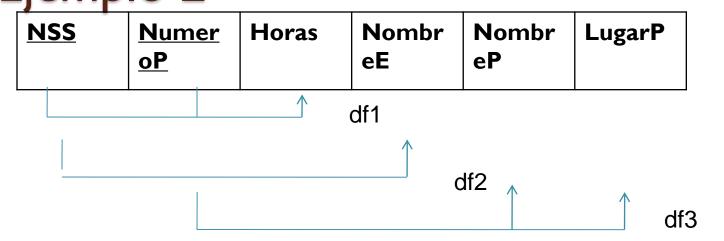
(Es decir, IFN y cada atributo no llave tiene dependencia funcional completa respecto a alguna de las llaves.)

SEGUNDA FORMA NORMAL 2FN Ejemplo I



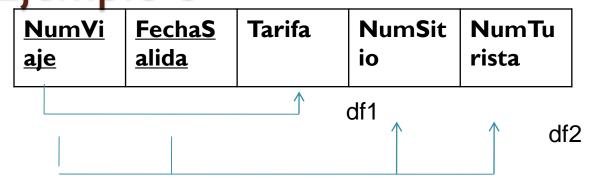
• Tiene <u>problemas de insertar, borrar y modificar,</u> por ejemplo nó puede insertar precio de entrega si no hay un cliente que compre algo. Tiene problemas de borrado su borra el último cliente desaparece la información de precio de entrega.

SEGUNDA FORMA NORMAL 2FN Fiemple 2



- Relación Emp_Pry
- Tiene <u>problemas de insertar, borrar y modificar</u>, por ejemplo nó puede insertar proyecto si no tiene empleado asociado.
 Tiene problemas de borrado si borra el último empleado de un proyecto desaparece la información del proyecto.

SEGUNDA FORMA NORMAL 2FN Ejemplo 3



Relación Itinerario

 Tiene problemas de insertar, borrar y modificar, por ejemplo nó puede insertar viaje si tiene fecha de salida programada.
 Tiene problemas de borrado si borra la única fecha salida realizada de un viaje pierde el sitio y los turistas que partic.

SEGUNDA FORMA NORMAL

- Solución:
- Quitar de la relación IFN todos los campos no llaves que no son totalmente funcionalmente dependientes de la llave primaria.
- Guardar los campos nuevos que fueron quitados en el punto anterior, en relaciones nuevas y adecuadas.
- Pueden persistir problemas.

Aplicación de la 2FN Ejemplo I

• Tabla I:

NumCliente → NomCliente, CiudadCliente,
PrecioEntrega

• Tabla 2:

NumInv -> PrecioUnitario

• <u>Tabla 3:</u>

{NumCliente, NumInv, Fecha} → Cantidad

Aplicación de la 2FN Ejemplo 2

Tabla I:{ NSS, NumeroP } → Horas

• Tabla 2:

NSS → NombreE

• <u>Tabla 3:</u>

NumeroP → NombreP, LugarP

Aplicación de la 2FN Ejemplo 3

• Tabla I:

{ NumViaje, FechaSalida} → NumSitio,
NumTuristas

• <u>Tabla 2:</u>

NumViaje → Tarifa

TERCERA FORMA NORMAL 3FN

Se dice que una relación R se encuentra en tercera forma normal si se encuentra en 2FN y ningún atributo no llave es funcionalmente dependiente de algun otro atributo no llave.

(Es decir, si 2FN y se cumple la DF
X → A, entonces S es la superllave de R
o A es atributo primo de R(es decir, A
forma parte de la llave candidata))

3FN Ejemplo I

10000000	Num Cliente	Numlnv	<u>Fecha</u>		PrecioE ntrega	Cantida d
					^	

Aplicación de la 3FN

Tabla I.a

df4

Tabla 1.b

CiudadCliente → PrecioEntrega

3FN Ejemplo 3

<u>NumViaje</u>	FechaSali da	Tarifa	NumSitio	NumTuris ta
			<u>^</u>	df

Se va a suponer que cada turista visita un solo sitio durante el año (df3). Num_turista -> num_sitio

Aplicación de la 3FN

Tabla I.a

{ NumViaje, FechaSalida} → NumTurista

Tabla I.b

NumTurista -> NumSitio

3FN Ejemplo 4

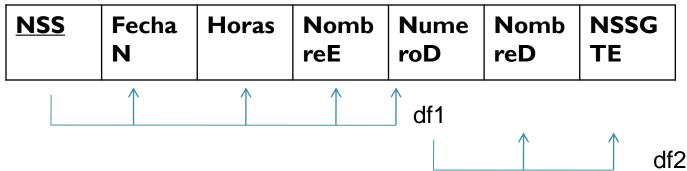


Tabla I

NSS → FechaN, Horas, NombreE, NumeroD, NombreD,

Aplicación de la 3FN

NSSGTE

Tabla I.a

NSS -> FechaN, Horas, NombreE, NumeroD

Tabla 1.b

NumeroD → NombreD, NSSGTE

TERCERA FORMA NORMAL Boyce Codd 3FNBC.

Una relación se encuentra en 3FNBC si está en 3FN y todos los atributos son determinados solo por llaves, es decir, si cada vez que: $X \rightarrow A$, $A \notin X$

(Si 3FN y si la DF X → A existe en R, X es la llave candidata de R. No esta en 3FNBC si X no es llave primaria y A es un atributo de la llave primaria)
 Si está en 3FNBC está en 3FN, no viceversa.

TERCERA FORMA NORMAL BC

Ejemplo 3

NumViaje FechaSali da NumSitio NumTuris ta

Suponga que cada turista tiene una sola fecha de salida. Num_turista -> fecha_salida

Aplicación de la 3FNBC

Tabla I.a.I

NumViaje → NumTurista

Tabla I.a.2

NumTurista → FechaSalida

TERCERA FORMA NORMAL BC Ejemplo 5

- A cada estudiante de cada materia le enseña únicamente un profesor.
- Cada profesor enseña sólo una materia.
- Cada materia la enseñan varios profesores.

<u>Estudiante</u>	<u>Materia</u>	Profesor
Pérez	Matemática	Prf. Blanco
Pérez	Física	Prf.Verde
Jaramillo	Matemática	Prf.Blanco
Jaramillo	Física	Prf.Verde

TERCERA FORMA NORMAL BC Ejemplo 5

DF: {Estudiante, Materia} → Profesor

Aplicación de la 3FNBC

Tabla I

Profesor → Materia

Tabla 1.a.2

Estudiante → Profesor

TERCERA FORMA NORMAL 3FNBC

Cuando una relación esta compuesta solamente por atributos que pertenecen a la llave, se dice que esta en 3FNBC.

BENEFICIOS DE NORMALIZAR

- Reducir los problemas de inserción y supresión de datos.
- Reducir el tiempo asociado con la modificación de tuplas.
- Disminuir redundancia.
- Identificar problemas que pueden requerir un análisis adicional.

DEPENDENCIAS MULTIVALOR

 Sean X y Y dos descriptores, X multidetermina a Y si para cada valor de X existe un conjunto bien definido de valores posibles en Y, con independencia del resto de atributos de la relación.

 $\bullet X \rightarrow \rightarrow Y$

DEPENDENCIAS MULTIVALOR

Dependencias MultivalorTRIVIALES:

• Si $A \rightarrow B$ entonces $A \subseteq B$ o $A \cup B = R$

Ejemplo:

- (nombre_madre, nombre_padre) → →
 nombre_hijo
- Si R($\{A,B\}$, $\{A \rightarrow \rightarrow B\}$)
- Si R($\{A,C\}$, $\{A \rightarrow C\}$)

DEPENDENCIAS MULTIVALOR

Dependencias Multivalor NO TRIVIALES:

• Si A $\rightarrow \rightarrow$ B no es trivial

Ejemplo:

NumInv →→ tamaño y
 NumInv →→ color y
 NumInv →→ preciounitario

• Si R($\{A,B,C\},\{A\rightarrow\rightarrow B;\{A\rightarrow\rightarrow C\}\}$)

Se dice que una relación R se encuentra en cuarta forma normal respecto a un conjunto de dependencias $F(que incluye dependencias funcionales y multivaluadas) si, para cada dependencia multivaluada no trivial <math>X \rightarrow Y$, X es una superllave de R.

Si no está en 4FN posee redundancia de datos, por lo que se necesita descomponer las DMV en triviales.

Nos interesan las DMV no triviales.

Así una relación debe tener una llave compuesta por al menos tres atributos antes de que pueda ocurrir una <u>DMV no trivial</u>.

Por lo tanto, una relación en 3FN con una llave primaria primaria con menos de tres atributos está automáticamente en 4FN.

Ejemplo:

Num Inv	Precio	Color	Tamaño
	Unitario		

NumInv → → Tamaño

NumInv $\rightarrow \rightarrow$ Color

NumInv → → PrecioUnitario

Aplicación de la 4FN:

tabla I: NumInv, PrecioUnitario

tabla 2: Numlny, Color

tabla 3: Numlny, Tamaño

- Genera menos tuplas que la relación en 3FN o 3FNBC.
- Las tuplas son más pequeñas que las originales.
- Se evitarán anomalías de actualización asociadas a las dependencias multivaluadas y problemas de eliminación.

QUINTA FORMA NORMAL 5FN

- Se dice que una relación se encuentra en 5FN (de proyección reunión) si y sólo si:
 - Se encuentra en 4FN
 - Toda dependencia funcional o multivaluada no trivial es consecuencia de las claves candidatas.

 No está en 5FN si tiene dependencias funcionales multivaluadas en las que no se dependa de la clave.